

基于 CLR 的玻璃文物成分分析与分类模型

邓天宇, 邱奕琚, 池正昊

(复旦大学 管理学院, 上海 200433)

摘 要: 对具有成分数据特征的古代玻璃成分数据集进行风化前成分含量预测以及类别划分。首先, 对成分数据进行中心对数比变换预处理, 从“成分相对重要性”的角度提取了成分数据的信息, 并通过对变换后的玻璃文物化学成分数据分析: 一方面, 实现了对已风化的铅钡和高钾两类玻璃风化前化学成分预测, 即成分还原; 另一方面, 在铅钡和高钾两大类的基础上, 筛选出可用于对玻璃文物进一步分出亚类的化学成分, 构建了稳健的玻璃亚类分类模型。该模型可以实现在风化导致玻璃文物偏移其原始化学成分的情况下, 对玻璃的亚类有大致正确的判断, 即对风化文物原始成分的预测偏差不会显著影响分类结果。

关键词: 风化; 玻璃文物; 成分还原; 中心对数比变换; 层次聚类; 文物亚类划分

中图分类号: O29

文献标志码: A

文章编号: 2095-3070(2023)02-0041-11

DOI: 10.19943/j.2095-3070.jmmia.2023.02.04

0 引言

丝绸之路是古代中西方文化交流的通道, 其中玻璃是早期贸易往来的宝贵物证。玻璃的主要原料是石英砂, 主要化学成分是 SiO_2 。

由于纯石英砂的熔点较高, 为了降低熔化温度, 玻璃在炼制时需要添加助熔剂。古代常用的助熔剂有草木灰、天然泡碱、硝石和铅矿石等, 并添加石灰石作为稳定剂。石灰石煅烧以后转化为 CaO 。添加的助熔剂不同, 玻璃的主要化学成分也不同。然而, 古代玻璃极易受埋藏环境的影响而风化。在风化过程中, 内部元素与环境元素进行大量交换, 导致其成分比例发生变化, 从而影响对其类别的正确判断。

因此, 考古工作者需要一种分析风化后玻璃文物化学成分的方法, 让他们能在风化导致玻璃文物偏移其原始化学成分的情况下, 对该玻璃的类别有大致正确的判断。该方法至少包含如下两个步骤: 其一, 通过风化后的玻璃文物的化学成分预测其风化前的化学成分; 其二, 构建基于玻璃文物化学成分的文物流分类模型, 且由于步骤 1 的预测可能存在偏差, 该模型需要具有较好的鲁棒性。

2022 年“高教社杯”全国大学生数学建模竞赛 C 题^[1]以我国古代玻璃制品为研究背景, 着重分析其在风化前后的颜色、纹饰以及化学成分变化。该赛题旨在引导参赛者探究成分数据集所适用的分析方法, 并针对小样本数据集进行有监督、无监督的分类。赛题根据逻辑顺序由易到难设置了 4 个问题, 在此不再赘述。

收稿日期: 2023-01-24

通讯作者: 邱奕琚, E-mail: 20307100055@fudan.edu.cn

引用格式: 邓天宇, 邱奕琚, 池正昊. 基于 CLR 的玻璃文物成分分析与分类模型[J]. 数学建模及其应用, 2023, 12(2): 41-51.

DENG T Y, QIU Y H, CHI ZH H. Classification model for glass relics based on compositional data analysis through CLR transformation(in Chinese)[J]. Mathematical Modeling and Its Applications, 2023, 12(2): 41-51.

1 数据预处理

成分数据(compositional data)是一类特殊的数据,具有正定性,且当成分数据以百分比形式呈现时,各成分比例累加和应为 100%(定和约束).另外,成分数据具有尺度不变性(scale invariance)^[2],因此其信息全部蕴含在各成分相对大小之中,仅考察某成分比例的绝对大小具有误导性.最后,一般来说,成分数据具有高维、稀疏、分布严重右偏的特点^[3],这也是题目所给数据集的特点.综合以上特点,并结合参考文献,数据预处理主要从缺失值处理、对数据作中心对数比变换(centered log-ratio transformation, CLR)两方面着手.

1.1 数据说明

数据集有 69 行,20 列,共有来自 58 个文物上 69 个采样点的 14 种化学成分占比,以及 58 个玻璃文物的纹饰、文物类型和颜色等信息.

将成分比例累加和介于 85%~105%之间的数据视为有效数据,删除两条不符合此要求的数据.

1.2 缺失值处理

根据实际意义,成分数据中缺失值为“表示未检测到该成分”.对于本数据集,缺失值统一用 0.04 填充,其合理性体现在两方面:

其一,查阅文献发现,成分数据的缺失(或零值)通常可能由检测仪器测量下限值导致^[4].比如对于含量为 0.01%的某化学成分,可能因为仪器无法检出而被视作不含有该成分.考察本数据集,发现所有成分数据中的最小值为 0.04%,可认为 0.04%为仪器的测量下限值.

其二,在后续作数据中心对数比变换时,大量的缺失值、零值将导致转换后大量缺失值、Inf 的出现,因此对缺失值和零值作合理的填充很有必要.

1.3 中心对数比变换(CLR)

针对数据集,定义某文物的化学成分为 $\mathbf{x} = [x_1, x_2, \dots, x_D] \in S^D$, 其中: $D=14$ 表示化学成分的种类数; x_i 表示第 i 种化学成分在该文物所有成分中的占比.记 ξ 为经 CLR 变换后的数据, ξ_i 为变换后第 i 种成分(即 x_i)的对应值, CLR 变换公式如下^[5]:

$$\text{clr}(\mathbf{x}) = \left[\ln \frac{x_1}{g_m(\mathbf{x})}, \ln \frac{x_2}{g_m(\mathbf{x})}, \dots, \ln \frac{x_D}{g_m(\mathbf{x})} \right] = \xi = [\xi_1, \xi_2, \dots, \xi_D], \quad (1)$$

其中, $g_m(\mathbf{x})$ 是几何平均,即:

$$g_m(\mathbf{x}) = \sqrt[D]{\prod_{k=1}^D x_k} = \exp \left\{ \frac{1}{D} \sum_{k=1}^D \ln x_k \right\}. \quad (2)$$

对 $\text{clr}(\mathbf{x})$ 的分量进行简单代数运算后发现:

$$\xi_i = \ln \frac{x_i}{g_m(\mathbf{x})} = \ln x_i - \ln g_m(\mathbf{x}) = \ln x_i - \frac{1}{D} \sum_{k=1}^D \ln x_k, \quad (3)$$

易得 CLR 变换的逆变换为:

$$x_i = \exp \{ \xi_i \} / \sum_{k=1}^D \exp \{ \xi_k \}, i = 1, 2, \dots, D. \quad (4)$$

CLR 变换的必要性和意义在于解决了定和约束带来的分析困难问题,直观反映了成分的相对重要性.

从式(1)可以看出,CLR 变换后的指标不仅考虑了某成分占比的绝对大小,更考虑了该成分相比其他成分的相对大小,即相对重要性.例如,分别对物品一[30, 30, 40]与物品二[30, 10, 60]两条成分数据作 CLR 变换,结果分别为[-0.10, -0.10, 0.19]与[0.13, -0.96, 0.82].可以发现,两条数据的第 1 个分量虽然都是 30,但是由于其他成分组成不同,因此经过 CLR 变换后的分量值并不同.从两条数据也可以直观看出,第 1 种成分在物品二的构成的相对重要性要高于物品一.

从式(2)可以看出,CLR 的实质是对数据取对数后进行中心化处理(即 CLR 的命名由来),其不仅可以解决成分数据严重右偏的问题,而且经过 CLR 处理后的指标分量与 0 的大小关系体现了该成分的相对重要性是高于平均还是低于平均.

另外,成分数据的重要特点是其定和约束的存在,这导致对原始成分数据直接作统计分析时存在大量不便. CLR 变换通过构建一种欧氏空间与另一与之同构的赋范线性空间之间的等距变换的方式,在理论上为合理操作、解释成分数据提供保障——可以用熟悉的欧氏空间中的运算方法来处理 CLR 变换得到的数据后,再通过式(3)得到处理后的成分数据.

2 利用文物风化后的化学成分预测其风化前的化学成分

2.1 玻璃表面风化与其类型、纹饰和颜色的关系

首先考察类型、纹饰和颜色是否与玻璃表面风化有关,若是,则后续构建成分还原模型时需要考虑这些因素对文物风化效果的影响.

玻璃表面是否风化以及玻璃类型、纹饰和颜色均为定类变量,考虑以表面风化为结果变量,分别与类型、纹饰、颜色构造列联表. 对于 $r \times c$ 的列联表,若其总样本数大于 40 且每个类别的理论频数大于等于 5,则使用卡方检验;对于不符合卡方检验要求的小样本数据,利用 Fisher 精确检验.

表面风化与类型、纹饰和颜色构造的列联表,以及使用的假设检验方法和检验结果如表 1 所示.

表 1 表面风化与纹饰、类型、颜色的独立性检验 ($\alpha=0.05$)

变量	名称	表面风化		总计	假设检验方法	P 值
		无风化	风化			
纹饰	A	11	11	22	Fisher 精确检验	0.0836
	B	6	0	6		
	C	17	13	30		
合计		34	24	58		
类型	高钾	6	12	18	卡方检验	0.0195
	铅钡	28	12	40		
合计		34	24	58		
颜色	黑	2	0	2	Fisher 精确检验	0.6160
	蓝绿	9	6	15		
	绿	0	1	1		
	浅蓝	12	8	20		
	浅绿	1	2	3		
	深蓝	0	2	2		
	深绿	4	3	7		
	紫	2	2	4		
合计		30	24	54		

结论:从独立性检验的结果可知,给定显著性水平 $\alpha=0.05$,针对纹饰与风化、颜色与风化的假设检验,均没有充足理由拒绝原假设,即不能认为颜色和纹饰对玻璃是否风化有显著影响,符合直观认识. 而玻璃类型与风化的假设检验中, p 值充分小,有充足理由拒绝原假设,认为玻璃类型与是否风化具有关联性.

接下来将结合玻璃的类型分析文物样品表面有无风化时的化学成分含量的统计规律,并根据风化点检测数据,预测其风化前的化学成分含量.

2.2 预测模型:根据风化点数据,预测其风化前各成分含量

根据风化文物的化学成分含量数据预测其风化前的成分是一项现实且重要的工作. 化学成分含量信息是考古学家推定文物的具体年代、地域以及制造工艺的重要基础,是考古学中文物鉴定的重要手段.

本模型的预测目标是:针对文物某一部位,根据其风化后的成分数据预测其风化前的成分. 但是在已给出的数据集中,只有 49 号文物有风化前后的成分数据,其他文物都是不同部位在不同风化状态

下的数据。这导致在已有数据中,无法精确将某一风化后的成分数据对应到另一风化前的成分数据,因此在建立预测模型时,无法使用传统回归模型。

两类玻璃风化前后的化学成分相对含量的均值见表 2。可以看出,对于高钾、铅钡两种类型的玻璃,它们风化前后化学成分含量的变化呈现出不同的统计规律。比如,高钾玻璃和铅钡玻璃风化前后的 Na_2O 含量呈相反的变化趋势——风化后,高钾玻璃中钠的相对含量上升较多,而铅钡玻璃的钠相对含量则小幅下降。

表 2 两类玻璃风化前后各化学成分相对含量均值表

化学成分	铅钡风化	铅钡无风化	高钾风化	高钾无风化	铅钡玻璃风化前后均值差	高钾玻璃风化前后均值差
SiO_2	3.130	4.168	5.886	4.430	1.038	-1.456
Na_2O	-2.643	-1.104	-1.876	-1.945	1.539	-0.069
K_2O	-2.449	-1.810	0.120	2.043	0.639	1.923
CaO	0.712	-0.118	1.034	1.172	-0.830	0.138
MgO	-1.314	-0.976	-0.980	-0.171	0.338	0.809
Al_2O_3	0.841	1.483	1.893	2.040	0.642	0.147
Fe_2O_3	-1.416	-1.434	-0.016	0.185	-0.018	0.201
CuO	0.146	-0.224	1.639	0.654	-0.370	-0.985
PbO	3.763	3.220	-1.876	-1.576	-0.543	0.300
BaO	1.780	2.216	-1.876	-1.760	0.436	0.116
P_2O_5	0.957	-1.100	-0.197	0.019	-2.057	0.216
SrO	-1.093	-1.489	-1.876	-2.668	-0.396	-0.792
SO_2	-2.412	-2.831	-1.876	-2.423	-0.419	-0.547

基于以上原因,分别求出高钾、铅钡玻璃风化前后各成分相对含量均值差 $\Delta\xi_{\text{mean}}$,并通过风化后成分加上均值差的方法预测该部位风化前的相对含量:

$$\xi_{\text{erode}} + \Delta\xi_{\text{mean}} = \xi_{\text{predict}}, \quad (5)$$

其中: ξ_{erode} 为风化后的相对含量; ξ_{predict} 为预测后的含量。

这样做的合理性和好处有 5 点:

- 考虑了风化对不同种类玻璃相对成分的影响;
- 在响应变量和解释变量的样本不具有明确一一对应关系的情况下,防止盲目套用回归模型导致过大的预测偏差;
- 充分利用了风化前的数据信息;
- 预测方法相对直观,解释性强;
- 不易受严重风化点的干扰。

通过以上方法得到的已风化铅钡、高钾玻璃文物风化前化学成分预测结果如表 3 和表 4 所示。经检验,预测结果满足成分数据的定和约束。

表 3 已风化铅钡玻璃文物风化前化学成分预测结果表

文物采样点	SiO_2	Na_2O	K_2O	CaO	MgO	Al_2O_3	Fe_2O_3	CuO	PbO	BaO	P_2O_5	SrO	SO_2
2	69.02	0.13	1.34	0.69	1.11	7.33	1.23	0.12	18.58	0.04	0.31	0.09	0.02
8	42.12	0.14	0.06	0.48	0.04	1.88	0.03	5.32	12.35	35.79	0.34	0.18	1.26
08 严重风化点	13.49	0.19	0.08	1.44	0.06	2.18	0.04	2.25	19.55	49.10	1.00	0.37	10.25
11	65.25	0.13	0.27	1.05	0.68	3.51	0.03	2.34	10.16	15.55	0.83	0.17	0.02
19	63.88	0.14	0.06	0.98	0.63	5.17	1.00	1.85	19.00	6.32	0.86	0.10	0.02

续表 3

文物采样点	SiO ₂	Na ₂ O	K ₂ O	CaO	MgO	Al ₂ O ₃	Fe ₂ O ₃	CuO	PbO	BaO	P ₂ O ₅	SrO	SO ₂
26	41.53	0.14	0.06	0.47	0.04	0.99	0.03	5.42	12.76	37.08	0.30	0.23	0.96
26 严重风化点	10.35	0.18	0.75	1.29	0.06	2.21	0.04	2.45	17.14	54.03	0.76	0.41	10.34
34	67.61	0.12	0.32	0.23	0.04	2.06	0.31	0.70	18.11	10.35	0.03	0.10	0.02
36	66.70	6.18	0.16	0.10	0.03	1.81	0.19	0.28	14.44	10.00	0.01	0.09	0.02
38	62.12	4.30	0.05	0.20	0.04	3.26	0.19	0.34	19.15	10.12	0.04	0.18	0.02
39	59.89	0.15	0.06	0.39	0.05	0.77	0.03	0.49	28.67	9.03	0.12	0.33	0.02
40	46.59	0.18	0.07	0.81	0.06	0.84	0.18	0.03	40.31	10.22	0.22	0.45	0.03
41	47.65	0.17	0.76	1.98	3.50	5.78	1.61	0.12	23.45	13.80	0.87	0.29	0.02
43 部位 1	37.24	0.20	0.08	2.43	1.33	4.54	0.79	3.93	36.98	11.99	0.01	0.46	0.03
43 部位 2	56.95	0.17	0.07	2.59	1.24	6.02	1.27	0.97	24.18	4.69	1.53	0.29	0.02
48	73.08	1.81	0.29	0.60	1.05	12.58	0.49	0.01	4.43	5.49	0.07	0.08	0.01
49	62.50	0.14	0.06	1.54	1.58	7.85	2.07	0.37	15.28	7.26	1.09	0.24	0.02
50	47.64	0.17	0.07	1.31	0.62	3.33	0.30	0.73	24.01	20.62	0.76	0.42	0.02
51 部位 1	56.21	0.15	0.06	1.26	1.35	8.06	0.95	0.77	18.93	11.19	0.84	0.21	0.02
51 部位 2	59.34	0.18	0.07	2.20	2.00	4.69	0.41	0.51	29.38	0.06	1.10	0.03	0.03
52	58.10	4.55	0.06	0.79	0.62	1.76	0.18	0.39	22.04	10.68	0.58	0.24	0.02
54	52.57	0.16	0.51	1.16	1.50	6.58	0.03	0.48	26.94	9.10	0.45	0.49	0.02
54 严重风化点	51.03	0.20	0.08	0.02	1.64	7.32	0.04	0.98	35.90	0.07	1.91	0.80	0.03
56	60.74	0.14	0.06	0.39	0.04	2.59	0.03	0.40	17.70	17.64	0.24	0.02	0.02
57	54.92	0.14	0.06	0.44	0.04	3.17	0.03	0.61	20.06	20.48	0.00	0.02	0.02
58	63.55	0.14	0.48	1.13	0.82	4.95	0.63	1.60	16.94	8.78	0.85	0.12	0.02

表 4 已风化高钾玻璃文物风化前化学成分预测结果表

%

文物采样点	SiO ₂	Na ₂ O	K ₂ O	CaO	MgO	Al ₂ O ₃	Fe ₂ O ₃	CuO	PbO	BaO	P ₂ O ₅	SrO	SO ₂
7	77.59	0.13	0.98	4.41	0.32	8.24	0.75	4.35	0.19	0.16	2.72	0.07	0.08
9	73.60	0.12	13.41	2.36	0.30	5.08	1.30	1.92	0.18	0.15	1.44	0.06	0.08
10	72.82	0.12	20.31	0.78	0.29	3.03	1.03	1.01	0.17	0.14	0.16	0.06	0.07
12	66.96	0.11	21.04	2.52	0.27	5.15	1.08	1.88	0.16	0.14	0.57	0.06	0.07
22	61.41	0.11	14.44	5.44	4.10	11.56	1.22	0.59	0.15	0.13	0.74	0.05	0.07
27	75.76	0.13	0.96	3.78	4.25	10.19	0.86	2.02	0.19	0.16	1.57	0.06	0.08

3 高钾、铅钡玻璃划分依据及其亚类划分依据

现有数据集已经给出玻璃文物所属类别. 根据已有信息, 尝试采用有监督的支持向量机(support vector machine, SVM)方法来寻找划分高钾和铅钡玻璃的依据. 在此基础上, 又选取了关键指标, 利用无监督的聚类算法划分亚类, 并进一步采用 SVM 算法获得具体分类标准.

3.1 界定数据范围

在进行类别划分前, 首先需要界定分析数据的范围, 该规则同样适用于后续亚类的划分.

1) 只使用未风化点的数据

倘若使用风化点数据, 由于在部分成分的相对含量上风化前与风化后存在较大差距(如 SiO₂), 使用聚类算法时风化样本和未风化样本的组内距离小于组间距离, 尽管能得到很好的轮廓系数, 但区分出的簇与样本风化状态有关而与品类无关; 若利用问题 1 中得到的映射将风化点的数据变换为未风化点, 求平均的过程模糊了亚类特征, 会使得大量数据中的信息含量减少, 对聚类模型产生噪声.

2) 包含变量: Na₂O、CaO、MgO、Al₂O₃、Fe₂O₃

不包含问题 1 中含量较高的成分, 例如 SiO₂、BaO 和 PbO, 避免其较高的对数比对距离计算的影

响;不包含含量过低、非零样本量过少的成分,例如 SrO 和 ZnO,简化模型;不包含分布过于均匀的成分,例如 P_2O_5 ,根据问题 1 中描述型统计的分析,这部分均匀分布的变量很难作为聚类依据。

3.2 有监督条件下的分类方法选择——支持向量机

考虑到本题可使用的数据量有限,基于决策树的机器学习效果较差,首先尝试以 Logistic 回归对样本分类。Logistic 回归的模型呈现出明显的过拟合,这意味着样本线性可分。因此,在分析各成分分布特征后,选取 BaO 和 PbO 作为高钾玻璃、铅钡玻璃分类的主要依据。为了给出更明确的分类依据,选取适用于小样本、高维模式识别的支持向量机(SVM)^[6],如图 1 所示。相较于决策树分类,SVM 利用拉格朗日乘数法求解得到的最佳决策边界可以使各点距离该边界尽可能远,从而获取更为精确稳定的分类标准。

由于高钾玻璃和铅钡玻璃中 BaO 和 PbO 含量所构成的散点图线性可分,直接选择线性函数作为支持向量机的核函数,分析过程如下。

首先确定优化目标与约束条件,得到如下规划方程:

$$\begin{aligned} \min \quad & \lambda \omega^2 + \sum_{i=1}^N \xi_i \\ \text{s. t.} \quad & \begin{cases} \xi_i \geq 0, \\ y_i(\omega^T \mathbf{X}_i + b) \geq 1 - \xi_i, \end{cases} \end{aligned} \quad (6)$$

其中: $\mathbf{X}_i$ 表示每个样本点各种成分含量(经过 CLR 转化后的)组成的多维向量, $i=1, 2, \dots, N$; ω 与 b 为待求解的参数。

将铅钡玻璃与高钾玻璃的样本数据代入规划方程(6),得到如下结果。

此时,解得最优边界的函数表达式为:

$$\xi_{PbO} = -3.51\xi_{BaO} + 5.97, \quad (7)$$

由此,高钾玻璃和铅钡玻璃的分类规律可以概括为:若 $\xi_{PbO} + 3.51\xi_{BaO} - 5.97 > 0$,则样本属于铅钡玻璃;若 $\xi_{PbO} + 3.51\xi_{BaO} - 5.97 < 0$,则样本属于高钾玻璃。

3.3 无监督条件下分类方法选择——层次聚类+支持向量机

在给出高钾玻璃、铅钡玻璃的划分依据后,需要进一步探寻两者内部的亚类划分依据。

针对此类无监督分类问题,聚类算法是较为经典便捷的分类方法,但也存在着结果不够精确、分类标准不够清晰的问题。同时,由于层次聚类主要研究同一类别样本间的距离,难以精确给出不同类别样本的分类依据。结合上文采用的 SVM 算法,本文采取了非监督的层次聚类算法与有监督的 SVM 相结合的分类方法,这种方法能够在聚类算法的基础上给出更精确稳定的分类标准^[7],为后续分析提供依据。

3.3.1 层次聚类划分亚类

以 Ward 方法(Ward's minimum variance method),分别对高钾玻璃和铅钡玻璃的 CLR 数据集进行层次聚类。

假设已对 n 个样本进行分类,并且分类个数为 k ,第 t 类样本个数为 n_t ,重心为 $\bar{\mathbf{X}}^t$,定义总离差平方和 W :

$$W = \sum_{t=1}^k W_t = \sum_{t=1}^k \sum_{i=1}^{n_t} (\mathbf{X}_i^t - \bar{\mathbf{X}}^t)^T (\mathbf{X}_i^t - \bar{\mathbf{X}}^t). \quad (8)$$

以最小化离差平方和 W 为目标,对数据集的处理过程如下:

- 1) 将 n 个样本各自分为一类,此时 $W=0$;
- 2) 对其中某两个类进行合并,此时应满足使 W 的增加量最小;
- 3) 不断重复直至所有的样品归为一类。




图 1 SVM 分类器——高钾、铅钡分类规律

3.3.2 聚类过程和结果

3.3.2.1 高钾玻璃层次聚类

对划分好的高钾玻璃 CLR 数据集,依据上述聚类方法进行层次聚类,结果如图 2 所示。

观察聚类层次关系,在最大距离的垂直线处设置阈值($height=7$),得到 3 个聚类。

- 聚类 1: 3(部位 1)、13、14、16;
- 聚类 2: 1、3(部位 2)、4、5、6(部位 2)、21;
- 聚类 3: 6(部位 1)、18。

可以发现,不同聚类在 Na_2O 、 CaO 和 MgO 三个成分上有较好的区分度,聚类 1 为高钠高钙,聚类 2 为低钠高钙,聚类 3 为低钙高镁。

3.3.2.2 铅钡玻璃层次聚类

对划分好的铅钡玻璃 CLR 数据集,依据上述聚类方法进行层次聚类,结果如图 3 所示。




图 2 高钾玻璃层次聚类结果树状图




图 3 铅钡玻璃层次聚类结果树状图

观察聚类层次关系,在最大距离的垂直线处设置阈值($height=12$),得到 2 个聚类。

- 聚类 1: 42(部位 2)、33、23、29、32、47、30、25、44、45、28、53、35、31;
- 聚类 2: 49、55、20、37、42(部位 1)、24、30。

可以发现,不同聚类在 Na_2O 一个成分上有较好的区分度,聚类 1 为高钠,聚类 2 为低钠。

3.3.3 层次聚类总结

作为探索性分析的方法,层次聚类法为选择亚类和对应的指标提供了参考。在散点图中,可以发现部分成分也具有很好的区分度,呈现两极分布(例如铅钡玻璃中的 CaO),但 Na_2O 对于模型中的距离计算影响更大,所以这种成分的区分度并没有很好地为模型的亚类区分作参考;同时,在区分亚类时,还需要结合颜色、表面风化等分类变量和化学实践,这是该模型没有考虑到的。综上,结合层次聚类法的结果,基于简单高效的目标,设定了亚类如下:

- 高钾玻璃: 高钙低镁/低钙高钙;
- 铅钡玻璃: 高钠/低钠。

3.3.4 支持向量机求解亚类划分标准

根据层次聚类的结果与相关散点图分析,选定 CaO 和 MgO 为高钾玻璃分类的主要指标,分为高钙低镁、低钙高镁两类;铅钡玻璃则根据钠含量的高低分为高钠与低钠两类。

同样地,由于该分类标准下的亚类线性可分,选取线性核函数并构造二分类支持向量机,得到各亚类分类标准如下,分类结果如图 4 所示。




图 4 两种玻璃亚类分类结果

1) 高钾玻璃的分类标准

若 $\xi_{\text{MgO}} + 2.10\xi_{\text{BaO}} - 1.51 > 0$, 则样本属于高钙低镁玻璃; 若 $\xi_{\text{MgO}} + 2.10\xi_{\text{BaO}} - 1.51 < 0$, 则样本属于低钙高镁玻璃。

2) 铅钡玻璃的分类标准

若 $\xi_{\text{Na}_2\text{O}} + 0.10\xi_{\text{CaO}} - 0.75 > 0$, 则样本属于高钠玻璃; 若 $\xi_{\text{Na}_2\text{O}} + 0.10\xi_{\text{CaO}} - 0.75 < 0$, 则样本属于低钠玻璃。

3.4 亚类划分敏感性分析

针对支持向量机得到的分类标准, 选用梯度来反映分类边界对于某个样本成分改变的敏感性^[8]。给样本 i 的数据 $\mathbf{X}_i$ 一个微小扰动 $\boldsymbol{\theta}$, 其中, $\boldsymbol{\theta}$ 的维数与 $\mathbf{X}_i$ 一致。改变后的约束条件表达式如下:

$$\mathbf{y}_i(\mathbf{w}^T(\mathbf{X}_i + \boldsymbol{\theta}) + b) \geq 1 - \xi_i. \quad (9)$$

对原有数据添加扰动后, 在改变后的约束条件下重新求得最优分类曲线, 得到新的 $\boldsymbol{\omega}$ 和 b 。定义反映灵敏度的梯度 $\nabla[i]$:

$$\nabla[i] = d(\vec{\omega}, \vec{b}) / d\vec{\theta}. \quad (10)$$

为了求 $\nabla[i]$ 的最大值, 多次取 $\boldsymbol{\theta}$, 控制模长 $|\vec{\theta}|$ 一致, 将 $\boldsymbol{\omega}$ 与 b 的变化量的模长(分别表述为 $|\vec{d\omega}|$ 和 $|\vec{db}|$) 最大值加总

$$\nabla[i]_{\max} = |\vec{d\omega}|_{\max} + |\vec{db}|_{\max}. \quad (11)$$

分别对现有分类样本中的各点计算梯度 $\nabla[i]_{\max}$, 得到图 5 所示结果。图中点的半径大小表示其梯度大小, 越大说明分类边界对该样本点扰动越敏感。为了更清晰地呈现结果, 图 5 中梯度小于最大梯度十分之一的点统一采用最大点半径的十分之一表示。




图 5 两类玻璃分类结果敏感性分析

观察图 5 可以发现, SVM 算法的特性导致距离分类边界最近的点具有较高梯度, 其余点的微小变化对模型影响小, 模型整体稳定性较好。在高钾玻璃的分类结果中, 采样点 18、27 以及采样点 06 部位 1 具有较高梯度, 分别为 0.3182、0.1645 和 0.1459。

同理, 铅钡玻璃的分类结果中, 23 未风化点、采样点 48 和 54 严重风化点具有较高梯度, 分别为 1.2335、1.0545 以及 0.3945。

在对数据的审查中应当着重关注以上高梯度点, 因为其成分即使只有微小的不确定性, 也将极大地影响分类标准。

3.5 亚类划分结果与合理性分析

表 5 和表 6 分别给出了各亚类所包含的样本点编号及其对应的主要特征。

表 5 铅钡玻璃亚类划分结果及主要特征表

亚类	包含样本点	主要特征
高钠	23, 25, 36, 38, 42, 44, 45, 47, 48, 52, 53, 54, 54(严重风化)	多数呈浅蓝色, 更加容易风化
低钠	2, 8, 11, 19, 20, 24, 26, 28, 29, 30, 31, 32, 33, 34, 35, 37, 39, 40, 41, 43, 46, 49, 50, 51, 56, 57, 58	颜色相对深, 风化比例小

表 6 高钾玻璃亚类划分结果及主要特征

亚类	包含样本点	主要特征
低钙高镁	6, 18	多数呈深蓝色, 不易风化
高钙低镁	1, 3, 4, 5, 7, 9, 10, 12, 13, 14, 16, 21, 22, 27	多数呈蓝绿色

从以上亚类划分结果来看, 不同亚类在颜色、抗风化程度上体现出不同特征, 说明当前分类具有合理性.

4 未知类别文物亚类划分

根据上文 SVM 分类器得到的大类与亚类划分标准, 可以通过两次判定对未知类别文物作出亚类划分. 相关数据和划分结果如表 7 和表 8 及图 6 所示.

表 7 未知类别文物化学成分数据表

文物 编号	表面 风化	SiO ₂	Na ₂ O	K ₂ O	CaO	MgO	Al ₂ O ₃	Fe ₂ O ₃	CuO	PbO	BaO	P ₂ O ₅	SrO	SO ₂
A1	无风化	78.45	0.04	0.04	6.08	1.86	7.23	2.15	2.11	0.04	0.04	1.06	0.03	0.51
A2	风化	37.75	0.04	0.04	7.63	0.04	2.33	0.04	0.04	34.3	0.04	14.27	0.04	0.04
A3	无风化	31.95	0.04	1.36	7.19	0.81	2.93	7.06	0.21	39.58	4.69	2.68	0.52	0.04
A4	无风化	35.47	0.04	0.79	2.89	1.05	7.07	6.45	0.96	24.28	8.31	8.45	0.28	0.04
A5	风化	64.29	1.2	0.37	1.64	2.34	12.75	0.81	0.94	12.23	2.16	0.19	0.21	0.04
A6	风化	93.17	0.04	1.35	0.64	0.21	1.52	0.27	1.73	0.04	0.04	0.21	0.04	0.04
A7	风化	90.83	0.04	0.98	1.12	0.04	5.06	0.24	1.17	0.04	0.04	0.13	0.04	0.11
A8	无风化	51.12	0.04	0.23	0.89	0.04	2.12	0.04	9.01	21.24	11.34	1.46	0.31	2.26

表 8 未知类别文物化学成分数据表 (CLR 变换后)

文物 编号	表面 风化	SiO ₂	Na ₂ O	K ₂ O	CaO	MgO	Al ₂ O ₃	Fe ₂ O ₃	CuO	PbO	BaO	P ₂ O ₅	SrO	SO ₂
A1	无风化	4.88	-2.70	-2.70	2.32	1.14	2.50	1.28	1.26	-2.70	-2.70	0.58	-2.99	-0.16
A2	风化	4.63	-2.22	-2.22	3.04	-2.22	1.85	-2.22	-2.22	4.54	-2.22	3.66	-2.22	-2.22
A3	无风化	2.99	-3.69	-0.16	1.50	-0.68	0.60	1.48	-2.03	3.21	1.07	0.52	-1.12	-3.69
A4	无风化	2.96	-3.83	-0.85	0.45	-0.56	1.34	1.25	-0.65	2.58	1.51	1.52	-1.88	-3.83
A5	风化	3.87	-0.11	-1.29	0.20	0.56	2.25	-0.50	-0.35	2.21	0.48	-1.95	-1.85	-3.51
A6	风化	5.70	-2.05	1.47	0.72	-0.39	1.59	-0.14	1.72	-2.05	-2.05	-0.39	-2.05	-2.05
A7	风化	5.69	-2.04	1.16	1.30	-2.04	2.81	-0.24	1.34	-2.04	-2.04	-0.86	-2.04	-1.02
A8	无风化	3.85	-3.31	-1.56	-0.20	-3.31	0.66	-3.31	2.11	2.97	2.34	0.29	-1.26	0.73




图 6 将 SVM 所得的分类模型应用于新数据集后的文物分类结果

在图 6 中,“X_Before”为根据公式(5)所推测的样本 X 风化前成分的相对含量数据。可以看出,除了 A5 样品以外,其他文物样品均能被分类器完美区分,尤其是已风化样品 A2、A6 的 A7,经过还原其原始相对成分含量数据以后(即考虑了风化对其相关化学成分相对含量的影响趋势),依然能够被分类器划分。该分类器可以有效地对风化后的玻璃文物作亚类区分。

样品 A5 在第一次分类中被判定为铅钡玻璃,从铅钡玻璃的总体风化情况看,其钠的相对含量会有所上升,而钙的相对含量会显著下降。因此,铅钡玻璃的风化倾向于朝低钠亚类发展。而 A5 经过风化后依然保持了相对较高的钠含量,则分类器据此判定 A5 在风化前属于铅钡高钠亚类。

综上所述,未分类样品的分类结果表明该分类器可以有效地对风化后的玻璃文物作亚类区分,并且结果具有较好的合理性与可解释性。

5 不同种类玻璃成分相关性分析

5.1 高钾玻璃成分相关性

对数中心化(CLR)处理过的成分数据对线性运算是封闭的,因此分别对铅钡玻璃和高钾玻璃对数中心化之后的数据集(均根据第 1 问结果还原为风化前数据)计算 Pearson 相关系数矩阵^[5],基于此进行两种玻璃成分的相关性分析,并基于分析结果给出可能的化学原理解释^[9-10]。

针对高钾玻璃数据集计算 Pearson 相关系数矩阵,得到如图 7 所示的热力图,颜色反映了相关系数的大小。

1)不考虑对数比方差偏小的变量:CaO、SrO、Fe₂O₃和 BaO;

2)高度线性相关的变量组合为 SiO₂-Al₂O₃、Na₂O-K₂O-SO₂和 Fe₂O₃-CuO;

3)以上组合中,组间几乎正交,即相关性不强
部分理论解释:

- 对于 SiO₂和 Al₂O₃,两者之间易以络合的方式形成 Si-O-Si 键、Si-O-Al 键,形成铝硅酸盐,即硅酸盐中的 SiO₄四面体的一部分由 AlO₄四面体取代组成,故两者之间含量可能存在一定的相似性。

- 对于 Na₂O和 K₂O,钠和钾作为同族元素性质相似,在制造高钾玻璃的过程中会加入草木灰(碳酸钾和少量磷)、泡碱(水合碳酸钠)、硝石(硝酸钾)等物质,故钠和钾的含量具有一定的相关性。

5.2 铅钡玻璃成分相关性

针对铅钡玻璃数据集计算 Pearson 相关系数矩阵,得到如图 8 所示的热力图,颜色反映了相关系数大小。

1)对数比变化偏小的变量:K₂O、SrO。

2)高度线性相关的变量组合为:

- BaO-CuO-MgO[负相关]-Fe₂O₃[负相关];

- P₂O₅-CaO-Na₂O[负相关]。

3)以上组合中,组间几乎正交,即相关性不强。

部分理论解释:

- 关于 BaO-CuO-MgO 组合,由于镁钡作为同族元素,性质具有相似性,故具有强线性关系,而铜和镁都能提供氧化层保护以阻碍金属离子移动,达到




图 7 CLR 后高钾玻璃数据集的相关系数矩阵热力图(彩图见封三)




图 8 CLR 后铅钡玻璃数据集的相关系数矩阵热力图(彩图见封三)

防风化的目的, 在功能上相互有替代性(混合碱效应和阻塞效应).

5.3 高钾玻璃和铅钡玻璃成分关系对比

• 变量对数比的大小方面, 铅钡玻璃整体上是高度变化的, 但作为铅钡玻璃主要成分之一的 PbO 的相对含量却基本上没有变化, K_2O 和 SrO 也基本保持稳定; 高钾玻璃变化大的变量相对较少, 除去 CaO 、 SrO 、 Fe_2O_3 和 BaO , 其他的成分相对含量都基本稳定.

• 变量对数比的相关性方面, 铅钡玻璃有强相关性的是 BaO-CuO-MgO [负相关]- Fe_2O_3 [负相关]、 $\text{P}_2\text{O}_5\text{-CaO-Na}_2\text{O}$ [负相关]; 高钾玻璃是 $\text{SiO}_2\text{-Al}_2\text{O}_3$ 、 $\text{Na}_2\text{O-K}_2\text{O-SO}_2$ 、 $\text{Fe}_2\text{O}_3\text{-CuO}$. 并且相对而言, 高钾玻璃存在线性相关关系的变量对数比之间的相关系数更接近 1 或 -1(余弦值绝对值更大).

参考文献

- [1]全国大学生数学建模组委会. 2022“高教社杯”全国大学生数学建模竞赛赛题[EB/OL]. [2022-09-15]. http://www.mcm.edu.cn/html_cn/node/5267fe3e6a512bec793d71f2b2061497.html.
- [2]Egozcue J J. Analysis of compositional data[M]. West Sussex: Wiley, 2015.
- [3]Gerald K. Analyzing compositional data with R[M]. New York: Springer, 2011.
- [4]Filzmoser P. Applied compositional data analysis[M]. New York: Springer, 2018.
- [5]Filzmoser P. Correlation analysis for compositional data[J]. Math Geosci, 2009, 41: 905-919.
- [6]张学工. 关于统计学习理论与支持向量机[J]. 自动化学报, 2000, 26(1): 36-46.
- [7]居红云, 张俊本, 李朝峰, 等. 基于 K-means 与 SVM 结合的遥感图像全自动分类方法[J]. 计算机应用研究, 2007, 24(11): 318-320.
- [8]Park J. Uncertainty and sensitivity in support vector machines[D]. Oklahoma: University of Oklahoma, 2006.
- [9]周良知. 影响硅酸盐玻璃风化的主要因素[J]. 大连工业大学学报, 1984, 1: 34-44.
- [10]王承遇, 陶琰. 硅酸盐玻璃的风化[J]. 硅酸盐学报, 2003, 31(1): 78-85.

Classification Model for Glass Relics Based on Compositional Data Analysis through CLR Transformation

DENG Tianyu, QIU Yihui, CHI Zhenghao

(School of Management, Fudan University, Shanghai 200433, China)

Abstract: We first apply centered log-ratio transformation on given compositional dataset of glass relics to capture information of "relative importance of a specific composition". After analysis on the transformed compositional data, we've achieved two main purposes. First, we can predict the pre-weathering composition of a glass relic using its known post-weathering composition. We call it as composition restoration. Second, selecting out reasonable criteria, we work out a robust subclass classification model for glass relics, which can accurately recognize the subclass of a weathered relic regardless of prediction bias caused by composition restoration. Our work is practically essential for archaeologists in face of weathered glass relics.

Key words: weathering; glass relic; composition restoration; centered logratio transformation; hierarchical clustering; subclass of relic

作者简介

邓天宇(2002—), 男, 复旦大学管理学院统计与数据科学系本科生.

邱奕琀(2002—), 男, 复旦大学管理学院金融与财务学系本科生.

池正昊(2002—), 男, 复旦大学管理学院统计与数据科学系本科生.